

Rush to Future AI & Cloud

Clush 회사소개 & AXELEON 소개

Agenda

I. Clush Overview

II. AXELEON

III. GPUaaS MSP

(주)클러쉬 — 대한민국 소버린 AX 전문기업

대규모 엔터프라이즈를 주요 고객으로 AI & Cloud Native 기술 서비스와 플랫폼을 제공합니다.

230명+

임직원

AI · Cloud Native 전담

407억

25년 매출

영업이익 22억 (연결기준)

591억

투자 유치

Series A · B · C(Pre-IPO)

2015.01

설립

*전신 케이비시스 (2024 사명변경)

주요 사업 영역


- AI Infra Management (GPUaaS) · AI Infra 운영 플랫폼
- AI / LLM 플랫폼 구축 및 AI Agent 개발
- Cloud & AI Native Application 개발 · 운영
- 폐쇄망 특화 대규모 엔터프라이즈 협업 플랫폼

회사 정보

회사명	(주)클러쉬
설립일	2015. 01. 14
대표이사	임정순
본사	서울 강남 테헤란로20길 9, 동궁빌딩 5F

(주)클러쉬 — History 및 Overview

Cloud Native 역량 기반으로 AI 시장 변화에 빠르게 대응하여 플랫폼 기반 Enterprise AX 전문사업자로 도약하고 있습니다.




(주)클러쉬 — Why Clush

AI & Cloud 영역의 E2E 역량을 보유하고 있는 기술 전문 회사로서 AI & Cloud Native 기술 역량과 노하우, 솔루션을 보유하고 있습니다.

하이닉스, KB은행, 우리은행, 매그나칩 등 한번 시작한 프로젝트는 5년 이상 함께 사업 수행

Legacy-Cloud-AI 통합 레퍼런스 및 AI & Cloud 영역의 E2E 역량 보유




- AI & Cloud Infra 데이터 수집부터 모델 개발, 운영, 거버넌스 자체 Product를 보유
- AI & Cloud 영역의 Infra/보안-App.-Data 전반의 E2E 역량을 갖춘 전문업체

금융·하이테크 제조 분야의 고도 규제 산업 전문성



- 규제, 데이터 거버넌스, 보안 등 산업 특화 규제 및 업무 프로세스 등 금융·하이테크 제조 산업 도메인 지식, 전문성 및 노하우 보유
- AI Agent 개발, AI Data Gov. 플랫폼 구축, 클라우드 아키텍처 구축, DevOps 플랫폼 구축, 그리고 AM*, MSA 경험 다수 보유

검증된 자체 기술 및 AI & Cloud Native 솔루션 보유



- 금융·하이테크 제조 등 규제 산업에서 검증된 제품들을 솔루션화하고, 지속 개선
- 기술에 대해 국제 특허 및 다양한 국내특허 획득, 클라우드 및 AI 관련 기술에 대한 표준체계 수립 및 CNCF 표준 인증 획득 및 확보 중

대규모 On-Prem/Private Cloud 및 GPU의 구축/운영 노하우



- 1,200개 이상의 GPU, 250개 이상의 GPU 노드 기반의 AI Infra 구축/운영 경험 보유
- 다수의 컨테이너 플랫폼 경험 보유하고 있으며 내외부 클라우드부터 Private 클라우드 아키텍처 기획 구축 부터 다양한 클라우드 경험 보유

AXELEON — 엔터프라이즈 AI Infra Management Platform

CNCF 인증 K8s 기반, 대규모 GPU 자원까지 최적화하는 운영 관리 플랫폼입니다.

01 포털 · 운영

분석 환경·모델 개발 신청 / Job·권한 관리
/ 통합 모니터링

02 AI 사용 환경

데이터 전처리·검증 / 모델 개발·훈련 / 테
스트·배포

03 모델 관리

모델 DB / 파이프라인 관리 / 오픈소스 관
리

04 인프라 관리

GPU 스케줄링 / Metric·Logging / K8s
오케스트레이션

특장점 (Differentiation)

- ✓ **CNCF Certified Kubernetes**
SK hynix · 우리금융그룹 검증된 CAI & Cloud PaaS
- ✓ **국내 최대 GPU Farm 운영 경험**
엔비디아 run:ai를 대체하는 Sovereign AI PaaS
- ✓ **DevSecOps Portal 전 주기**
개발 · 보안 · 운영 전 주기 지원
- ✓ **보안 · 규제 준수**
On-Prem · Private Cloud 환경 특화

AI & Cloud 운영관리 플랫폼의 De Facto 포지션

- ▶ 폐쇄망 On-Prem Private Cloud · 30,000 Unit 국내 최대
- ▶ 우리금융 그룹공동클라우드 표준 PaaS · 외산 Open Shift Win-back
- ▶ AWS · 해외 On-Prem · 글로벌 물류 APP 배포
- ▶ 초기 Apache Mesos → AXELEON 자체 플랫폼 전환

Clush GPUaaS 플랫폼 서비스

국내 최고 수준의 Kubernetes 기술력과 대규모 이기종 클러스터 운영 전문성으로, 국가AI컴퓨팅센터 GPUaaS 운영서비스 사업자로 최종 선정되었습니다.

국제 수준 K8s 기술 인증

CNCF Certified Kubernetes · 다수 국내외 특허

산업 특화 검증 솔루션

금융 · 하이테크 제조 검증 아웃풋 내재화

엔터프라이즈급 운영 전문성

약 13,000 노드 컨테이너 운영 경험

Private/Hybrid Cloud 구축·운영

국내 최고 수준의 실운영 사례 다수

AI Infra 코어 기술

이기종 GPU·NPU·CPU 통합 스케줄링

AI 전용 PaaS — AXELEON

엔터프라이즈급 GPU 구축·운영 해자 보유






주요 성과

국가AI컴퓨팅센터(전남 해남) — 삼성SDS · 네이버클라우드와 함께 GPUaaS 핵심 운영주체

- ▶ 28년 말까지 GPU 1.5만장 개소 · 향후 5만장 규모로 확대
- ▶ 국가 GPU 임차지원 사업 약 4,100장 GPUaaS 구축·운영 수행
- ▶ 국내 최대 규모 GPUaaS: H200 1,500장+ · Usable 26PB VAST 스토리지


다양한 산업에서 검증된 운영 레퍼런스

Clush는 제조·금융·서비스·공공·기타 산업에서 국내 최고의 대형 고객 및 랜드마크 레퍼런스를 보유하고 있습니다.

제조	금융	서비스	공공	기타
Hynix부터 산업 전방위 확산	국내 빅4 금융기관 레퍼런스 확보	다양한 도메인 대규모 플랫폼	보안·규제 충족 AI/Cloud 전환	기관별 대규모 SI 수행
 				
 				
				
 				
 	 			
 	 			
 				
 	 			 
				 

Cloud · AI · PaaS · Security 글로벌 파트너십

기업의 비즈니스 목적에 맞는 Cloud Infra-App-AI/Data를 제공하기 위해 글로벌 리더들과 지속적으로 협력하고 있습니다.



Agenda

I. Clush Overview

II. AXELEON

III. GPUaaS MSP

AXELEON

Enterprise AI Infra Management Platform

GPU 스케줄링을 넘어, 폐쇄망·이기종·대규모 AI 인프라를
하나의 운영 체계로 묶는 Single Control Plane

80%+

Hyperscale-led market

CSP·Neo Cloud 중심 성장

85%+

GPU utilization target

동일 인프라 효율 개선

13.5m

MTTR proven case

42dot 90분 대비 85% 단축

28


Multi-cluster ops

30,000 Pods 운영 실증

AI 인프라의 병목은 GPU 구매가 아니라, 전용 대규모 인프라를 운영하는 능력으로 이동했습니다.

투자는 인프라에 먼저 몰리고, 실제 효율은 자원배분·스케줄링·거버넌스 계층에서 결정됩니다.

Global AI spend



효율 병목

GPU 가동률은 이론 대비 50% 수준에 머무릅니다. 병목은 하드웨어가 아니라 자동화된 자원 공유, 동적 파티셔닝, 비용 통제, 수동 티켓팅에 있습니다.

구축 방식 변화

AI 인프라는 퍼블릭 클라우드와 달리 프라이빗·폐쇄망·전용 구축 방식으로 확산됩니다. 산업별 도메인과 운영 기준이 제품의 일부가 됩니다.

시장 구조

대규모 학습에서 추론과 AI Agent로 이동할수록 GPU·CPU·NPU와 애플리케이션 워크로드를 함께 보는 E2E 운영 역량이 필요합니다.

AXELEON은 GPU 스케줄러가 아니라, 엔터프라이즈 AI 인프라 운영 플랫폼입니다.

핵심은 특정 자원을 잘 배치하는 기능 목록이 아니라, 요청·정책·자원·감사·복구가 끊기지 않는 운영 모델입니다.

Resource Layer	GPU · NPU · CPU · Storage · Network
Platform Foundation	Kubernetes · Clush Kube · GPU Operator · CEF
Control Plane	State Collector · TTC Predictor · Queue Orchestrator · Placement
Service Layer	PlatformOps · MLOps · DevOps · DataOps · SecOps · FinOps
Enterprise Workloads	Training · Inference · AI Agent · Robot / Edge Apps


제품 정의

표준 K8s 위에서 멀티 클러스터, 이기종 자원, 멀티 스케줄러, 폐쇄망 거버넌스, AIOps 복구 절차를 하나의 Single Control Plane으로 통합합니다.

따라서 Clush의 경쟁력은 기능 단위가 아니라 실 운영 데이터와 운영 런북이 쌓이는 구조입니다.

Single Control Plane은 서로 다른 운영 도구를 하나의 정책·감사 체계로 묶습니다.

운영자는 도구별 화면을 오가는 대신 요청, 승인, 배포, 사용량, 장애 이력을 하나의 플랫폼 기준으로 축적합니다.



run:ai 대비 AXELEON 차별화

표준 GPU 스케줄링 기능은 업계 선도 제품과 동등 수준으로 구현했습니다. 그 위에 자체 개발한 3대 기술과 한국 운영 환경 차별화를 더했습니다.

항목	run:ai	AXELEON
표준 GPU 스케줄링 (Gang · Fractions · Bin Packing · Queue · Quota · Preemption · Fair-Share)	지원	지원 — 글로벌 표준 벤치마크 동등
잔여시간 예측 기반 선제 배치 (TTC)	—	자체 개발 / 특허 출원
단편화 제어·자원 재구성 (GDC)	—	자체 개발 / 특허 출원
GPU · NPU · CPU 이기종 통합 스케줄링	—	자체 개발 — run:ai 미지원
이벤트 백본 + AIOps 자율 복구 (CEF · GHE)	—	자체 개발 / 美 특허 (US11747986B2)
소유 주체 · 데이터 주권	NVIDIA(美) 자회사	한국 토종 · 폐쇄망 우선 설계
운영 지원	글로벌 SaaS 모델	230명+ 국내 전담 · 24/7 관제
한국 내 대규모 실운영 검증	—	42dot H200 1,528장 (한국 최대)
라이선스 통화	USD	KRW — 우리금융: 외산 의존 0

Clush는 한국에서 run:ai를 가장 큰 규모로 운영하는 회사 — 글로벌 표준 정통 + 한국 운영 환경 최적화

국내 최초 녹색기술 인증으로 검증된 GPU 자원 활용·전력 효율 기술

GPU 스케줄링·동적 자원 할당·능동형 POD 관리 기술이 정부 녹색기술 인증으로 외부 검증됐습니다.

기술 메커니즘

01 스케줄링·분할·동적 할당

GPU 자원을 작업·조직별로 분할하고 실시간 동적 할당. 프로젝트·팀별 멀티테넌시 격리

02 잔여시간 예측 선제 배치 (TTC)

완료 시점 예측으로 후속 작업을 사전 배치. 동적 할당의 진화형, GPU 점유 공백 최소화

03 능동적 POD 관리

Idle/Suspended 자원 자동 회수로 유휴 GPU 즉시 재 활용. 9-상태 머신 + 주기적 스캔

자원 효율·전력 효과

01 자원 활용률 극대화

50% → 85%+

GPU 자원 활용률 (녹색기술 인증 기준)

02 불필요한 전력 소모 감소

에너지 낭비 최소화

능동적 POD 관리로 유휴 자원 자동 회수 — 인증 검증 효과

외부 검증

녹색기술인증

GT-26-02618

과기정통부 / 인증일 2026.04.23

녹색기술제품확인

GTP-26-05469

과기정통부 / 확인일 2026.04.23

인증 검증 영역

동적 스케일링 · 워크로드 최적 배치
낭비 자원 감소 · 자원 효율 극대화


국내 최초 — 정부 인증으로 검증된 GPU 자원 효율·전력 절감 기술 (메커니즘 · 효과 · 외부 인증 3단계 완료)

GPU 효율은 현재 상태 수집이 아니라, 종료 시점 예측과 선제 재 배치에서 올라갑니다.

50% → 85%+

GPU utilization

동일 인프라 효율 개선 목표



기존 방식

잔여 자원은 있어도 연속 구획이 없어 대형 워크로드가 대기합니다.

Clush 방식

종료 예측 기반으로 빈 슬롯을 선점하고 단편화된 GPU를 연속 자원으로 재구성합니다.

엔터프라이즈 AI 운영은 신청·승인·배포·비용·감사를 남기는 워크북이 되어야 합니다.



- 1** 사용자 티어
SSO · OIDC/SAML · RBAC · 접근 이력
- 2** 프로젝트 티어
Quota · 워크스페이스 격리 · 승인 기반 운영 흐름
- 3** 조직 티어
멀티클러스터 공통 거버넌스 · 감사 로그 · 규제 리포트

핵심 메시지

PaaS의 본질은 배포 버튼이 아니라, 폐쇄망·금융권·GenAI 환경에서 운영 기준과 증빙을 반복 가능하게 만드는 능력입니다.

AIOps는 알림 도구가 아니라, 장애 이벤트를 복구 가능한 운영 판단으로 바꾸는 제품입니다.



1,528

H200 GPU

42dot 폐쇄망 운영 사례

90m → 13.5m

MTTR

복구시간 85% 단축

2%

HA spare pool

넉넉한 자원이 아니라 투입 기준이 필요한 운영 자원

현재는 승인 기반 자율 운영(v1), 다음 단계는 이벤트 백본과 GPU 자율 복구 엔진을 결합한 완전 자동 운영입니다.

제조·금융·소버린 GPUaaS에서 같은 제품 원리가 반복 검증됐습니다.

고객	규모	운영 난제	Clush 적용 기술	검증 결과
SK hynix	1만장급 GPU	외산 솔루션 운영 한계·조직 정책 충돌	K8s Native 통합 거버넌스	1만장 / 10명 운영 모델
우리금융	금융 클라우드	20억/년 라이선스·폐쇄망 한계	GPU·CPU·NPU 통합 컨트롤 플레인	외산 의존 0
42dot	H200 1,528장 (run:ai 기반 운영)	수동 운영·관제 이후 판단 병목	CEF 이벤트 백본 + 승인 기반 AIOps (AXELEON × run:ai)	MTTR 90분 → 13.5분

제품 소개서에서는 고객 로고보다 이 반복 패턴이 더 중요합니다: 폐쇄망·이기종·대규모 운영 난제를 하나의 운영 자산 체계로 바꾼다는 점입니다.

Clush의 우위는 기능 수가 아니라, 실운영 데이터가 제품을 계속 강하게 만드는 구조입니다.

01

핵심 거점 선점

국가 GPUaaS·대기업 Private Neo Cloud·금융 폐쇄망

02

운영 데이터 축적

장애 패턴·워크로드 분포·체크포인트 지연·재배치 결과

03

알고리즘 고도화

TTC·GDC·GHE 정확도와 정책 추천 품질 개선

04

고객 확장

운영 레퍼런스가 다음 고객의 도입 리스크를 낮춤

Agenda


I. Clush Overview

II. AXELEON

III. GPUaaS MSP

'18년 부터 SK 하이닉스 및 우리은행에서 MLOps 기반의 GPU Farm을 구축한 경험을 축적하고 있습니다.

SK hynix Cloud P/F 內 GPU 클러스터 ('18~)



- 2018년부터 전체 업무를 컨테이너 기반으로 전환
 - 10개 클러스터 13만개 노드로 구성
 - Data Platform 내 GPU 약 1,200ea 운영 중
 - 글로벌 최초 Windows 환경에 컨테이너 클라우드 구축(2018년)
 - 반도체 시뮬레이션 플랫폼으로 활용 중
- DevOps, MLOps 자동화
 - DevOps, MLOps 자동화 환경 제공
 - AI 경우, GPU 자원 프로비저닝 기능 제공
 - Kubeflow, JupyterLab, VsCode, Rstudio 기능 제공


우리은행 AI 서비스 플랫폼 ('20~)

AI 업무 운영	AI 서비스	AI 업무 서비스	시장예측 업무 서비스		MyData 분석	기업여신자동심사	로보어드바이저
		모델 서비스	VOC 모델 서비스	시장 예측 모델 서비스	STR 자동화 시스템	비정형자산화	
AI 플랫폼	AI 허브 포털	관리 포털	계정 관리	프로젝트 관리	배치 시스템 연동		AI 서비스 카탈로그
		AIOps (모델 서비스 배포)	모델 배포 파이프라인			모델 로깅/모니터링	
		DevAI(모델 개발)	IDE 서비스(R studio, jupyter)			모델 관리	
프라이빗 클라우드	클라우드 포털	관리 포털	사용자 관리	프로젝트 관리	모델 관리	클라우드 서비스 카탈로그	
			리소스 관리 & 정책	설정 & secret 관리	metering	멀티클라우드 관리	
	형상관리	Workflow	CI/CD 파이프라인				
		SCM	소스 코드 관리				
		mage registry	컨테이너 이미지 관리				
		Artifact manager	Library/framework 관리				
	컨테이너	시스템 서비스	Elasticsearh (로깅)	Prometheus (모니터링)		Nginx ingress controller (게이트웨이)	
		Orchestration	Konvoy				

- 국내 최초 AI 초개인화 금융 플랫폼
 - 2020년 최초 도입한 초개인화 AI 뱅커 플랫폼
 - <https://www.ddaily.co.kr/page/view/2021010715070396429>
 - 현재는 우리금융 전체의 GenAI 플랫폼으로 확대 적용 중
- GPU 전용 AIOps 환경 제공
 - 인프라 관점 : 자원 생성, 환경 구성, 설치, 회수, 변경 등 관리 프로세스 자동화
 - AI 관점: 구현, 학습, 재학습, AutoML, GenAI 프로세스 자동화 구축

N사의 GPUaaS 파트너로 1,528장 및 1,016장 규모의 GPU Farm을 성공적으로 구축 및 운영한 경험을 보유하고 있습니다.


42dot – Naver Cloud GPU Farm (1,528장)



- 국내 최대 H200 클러스터(191EA)
 - MIG 방식을 호환하는 국내 최대 클러스터
 - 고성능 분석을 위한 GDS 적용 사례
- 엔터프라이즈급 클러스터 관리
 - 관리 클러스터 기반 통합 모니터링 관리 기능
 - 자원 생성, 환경 구성, 설치, 회수, 변경 등 관리 프로세스 자동화
- GPU 전용 배포 체계 구성(GitOps)
 - GPU 전용 SW 배포 체계구성



NIPA GPU임차 지원 사업 (1,016장, 국가대표 AI 지원)



- GPU 1,016장 MSP 운영 경험
 - 고객 대상 GPU 사용 지원 및 운영관리 수행
- 고객 응대·지원
 - Teams/Discord 기반 질의 실시간 대응
- 운영 보고 체계 수립
 - 주간·월간 운영보고서 작성 및 현황 공유 및 GPU 사용량·노드 현황·주요 이슈 요약
- 운영 문서·체계 관리
 - 가이드·매뉴얼 제작 및 운영 이력 관리 및 고객 요구 분석 및 개선 포인트 정리


공공에서 제공하는 GPU 임차지원 사업에서 MSP로서 고객 1선 대응을 책임지고 있습니다.

NIPA 'AI 컴퓨팅자원 활용기반 강화' 사업 (3,056장)

- ✓ 서로 다른 기술 수준·사용 환경·사용 목적을 가진 사용자별 기술지원 및 SR 처리 프로세스를 제공해 효과적이고 안정적인 GPU 활용 지원
- ✓ 정기·비정기 교육과 VOC를 수집 및 반영해 사용 편의성과 서비스 품질을 지속적으로 개선하는 사용자 성공 체계 운영



필요충분한 지원 및 빠른 피드백을 제공함




GPU 특화 SLA·예방점검·모니터링·장애/SR 체계를 갖춘 GPUaaS 표준 운영 모델 보유

Clush GPUaaS 특화 표준 운영 체계

- ✓ 42dot SLA, Unhealthy GPU 자동 탐지 등 실운영 데이터를 통해 GPU 워크로드에 적합한 운영 방법론
- ✓ 이슈 유형·처리 패턴을 반영한 GPUaaS 맞춤형 표준화 운영 체계 수립 및 운영 중

IaaS 위주 MSP

대규모 GPUaaS 표준화 운영 체계



- 서버·네트워크 중심의 포괄적 SLA만 정의, 워크로드 특성별 세분화 기준은 미흡한 경우 존재
- 정기 하드웨어 상태 점검 위주로 수행, GPU 워크로드·Job 패턴까지 분석해 선제 대응하는 구조 부족 가능성 존재
- 자원 사용률·장애 알람 중심으로 모니터링, 제한적인 큐·Job·테넌트 단의 세밀한 관제나 이상 징후 관리에 있어서 제한적
- 공용 티켓 시스템에서 순차 처리하는 방식이 대부분, MLOps 특화 Runbook·Multi-User SR 프로세스 미흡
- 운영 이력·장애 사례가 개별 보고서나 이메일로 흩어져 관리, GPUaaS 전용 지식베이스와 정기 리포트 체계 미흡



Rush to Future Cloud & AI

Thank You

감사합니다

대표 전화: 02-2039-0100 / 주소: 서울시 강남구 테헤란로20길 9 동궁빌딩 5층